

MAKALAH

DATA MINING INTELECTA 2025

**MODEL *REGRESSION ENSEMBLE* UNTUK PREDIKSI SUHU TAHUNAN
MULTIVARIAT BERBASIS *MACHINE LEARNING* DAN *NAIVE FORECASTING***



INTELECTA CUP

Oleh:

Vidi Joshubzky Saviola	2341720112
Cakra Wangsa M.A.W	2341720032
Farrel Augusta Dinata	2341720081
Hidayat Widi Saputra	2341720157

COGNIVIO

POLITEKNIK NEGERI MALANG

ABSTRAK

Pemanasan global merupakan salah satu isu lingkungan utama yang memberikan dampak signifikan terhadap perubahan iklim di berbagai wilayah dunia. Salah satu indikator penting dalam memahami fenomena ini adalah perubahan suhu rata-rata tahunan. Penelitian ini bertujuan untuk memprediksi suhu rata-rata tahunan dengan pendekatan *time series forecasting* berbasis *machine learning* dan *ensemble learning* guna mendukung kebijakan adaptasi dan mitigasi perubahan iklim.

Dataset yang digunakan mencakup rentang tahun 1990 hingga 2024 dengan 14 fitur utama, antara lain curah hujan, emisi CO₂, hasil panen, dan indeks kesehatan tanah. Empat model dasar diterapkan menggunakan pustaka *Darts Python*, yaitu *Light Gradient Boosting Machine (LightGBM)*, *Extreme Gradient Boosting (XGBoost)*, *Naive Drift*, dan *Naive Seasonal*, yang kemudian dikombinasikan dalam pendekatan *Regression Ensemble Model*. Evaluasi performa dilakukan menggunakan metrik Mean Absolute Percentage Error (MAPE) sebagai ukuran akurasi prediksi.

Hasil penelitian menunjukkan bahwa Regression Ensemble Model memberikan performa terbaik dengan nilai MAPE sebesar 129,09%, yang menunjukkan kemampuan model dalam merepresentasikan tren kenaikan suhu tahunan secara konsisten pada data multivariat lintas wilayah. Model ini juga memiliki efisiensi komputasi tinggi dengan waktu pelatihan relatif singkat (<1 menit).

Penelitian ini menunjukkan bahwa kombinasi antara model *boosting* dan *naive forecasting* dapat menjadi alternatif yang efisien dan kompetitif untuk peramalan suhu tahunan, terutama pada dataset berukuran kecil dengan pola temporal yang kuat. Hasil ini diharapkan dapat menjadi referensi bagi peneliti dan pembuat kebijakan dalam memahami dinamika perubahan suhu global serta mendukung pengambilan keputusan berbasis data.

Kata Kunci: prediksi suhu, *time series forecasting*, *machine learning*, *Darts*, Python, MAPE

DAFTAR ISI

ABSTRAK	1
DAFTAR ISI	3
BAB 1 PENDAHULUAN	5
1.1 Latar Belakang	5
1.2 Rumusan Masalah	7
1.3 Tujuan	8
1.4 Manfaat	9
1.5 Batasan Masalah.....	9
BAB II PENELITIAN TERKAIT	11
2.1 Kajian Teori Umum	11
2.1.1 Perubahan Suhu Global dan Iklim	11
2.1.2 Konsep Time Series	12
2.1.3 Prinsip Dasar Forecasting	14
2.1.4 Data Mining dan Machine Learning dalam Forecasting.....	16
2.2 Implementasi Dataset Terkait	16
2.2.1 Sumber Data dan Horizon Waktu pada Penelitian Sebelumnya. 16	
2.2.2 Praktik Preprocessing pada Literatur Terdahulu.....	17
2.3 Implementasi Metode Terkait	19
2.3.1 Linear Regression Model	19
2.3.2 Naive Drift dan Naive Seasonal	20
2.3.3 Model-model gradient boosting	21
BAB III METODE PENELITIAN	23
3.1 Jenis dan Pendekatan Penelitian.....	23
3.2 Sumber dan Karakteristik Data	23

3.3 Analisis Awal Data	24
3.4 Preprocessing Data.....	24
3.5 Pemodelan dan Implementasi	25
3.5.1 Model dan Arsitektur	25
3.5.2 Hyperparameter dan Pelatihan	26
3.6 Evaluasi Model.....	27
3.8 Alur Penelitian	28
BAB IV HASIL DAN PEMBAHASAN	30
4.1 Gambaran Umum Data	30
4.2 Hasil Preprocessing Data dan Feature Engineering	33
4.2 Hasil Eksperimen	34
4.3 Analisis Perbandingan dan Diskusi.....	37
4.4 Ringkasan Hasil	38
BAB V PENUTUP.....	39
5.1 Kesimpulan	39
5.2 Saran.....	40
DAFTAR PUSTAKA	42
LAMPIRAN.....	45

BAB 1

PENDAHULUAN

1.1 Latar Belakang

Perubahan iklim kini menjadi ancaman ekologis, sosial, dan ekonomi yang nyata. Laporan ilmiah menyatakan bahwa aktivitas manusia, terutama pembakaran bahan bakar fosil dan perubahan penggunaan lahan seperti deforestasi, telah meningkatkan konsentrasi gas rumah kaca (GRK) di atmosfer. Peningkatan GRK seperti CO₂, CH₄, dan N₂O menyebabkan kenaikan suhu rata-rata permukaan Bumi secara sistematis dan berkelanjutan [1]. Deforestasi tropis sendiri menyumbang bagian signifikan dari emisi karbon antropogenik dan juga menyebabkan peningkatan panas lokal yang terukur. Selain mendorong percepatan pemanasan, hilangnya tutupan hutan ini berkorelasi dengan risiko kesehatan akibat paparan panas ekstrem pada populasi di wilayah tropis [2]. Dengan demikian, perubahan suhu tidak hanya menjadi isu fisik atmosferis, tetapi juga persoalan yang berdampak langsung terhadap kesejahteraan masyarakat.

Kenaikan suhu rata-rata tahunan memiliki konsekuensi jangka panjang terhadap berbagai sektor penting seperti ketahanan pangan, produktivitas pertanian, infrastruktur energi, stabilitas ekosistem, hingga perencanaan tata ruang wilayah. Peningkatan frekuensi dan intensitas kejadian ekstrem seperti gelombang panas, kekeringan, dan curah hujan intensif menambah urgensi untuk memahami dan mengantisipasi dinamika suhu di masa depan [1], [2], [8]. Oleh karena itu, proyeksi suhu bukan lagi sekadar kajian akademik, tetapi menjadi kebutuhan strategis untuk mitigasi risiko bencana, perencanaan adaptasi, serta penyusunan kebijakan lingkungan berbasis bukti.

Dalam konteks tersebut, pendekatan peramalan deret waktu (time series forecasting) digunakan untuk memprediksi suhu tahunan di masa depan dengan memanfaatkan pola historis suhu serta variabel lingkungan terkait [3], [4], [9], [10]. Data suhu tahunan umumnya memiliki struktur temporal yang

tidak acak: ada komponen tren jangka panjang yang merefleksikan pemanasan global, ada kemungkinan pola berulang yang khas secara regional atau musiman, dan ada variasi acak karena kejadian iklim ekstrem [1], [2], [9], [10]. Karena suhu tahunan meningkat secara bertahap dan terarah, model prediksi suhu harus mampu menangkap baik kecenderungan kenaikan jangka panjang maupun potensi pengulangan pola dari periode-periode sebelumnya.

Penelitian ini memposisikan perubahan suhu tahunan sebagai fenomena deret waktu yang memiliki tren peningkatan jangka panjang akibat akumulasi gas rumah kaca dan degradasi ekosistem, serta fluktuasi antartahun yang dipengaruhi dinamika iklim regional. Karena itu, pendekatan peramalan (forecasting) suhu tidak cukup hanya mendeskripsikan kondisi historis, tetapi harus mampu memproyeksikan nilai suhu ke depan secara kuantitatif dan dapat ditafsirkan untuk kebutuhan kebijakan adaptasi iklim [1], [2], [9], [10].

Untuk tujuan tersebut, penelitian ini membandingkan dua kelas pendekatan pemodelan. Kelas pertama adalah model dasar deret waktu (baseline) yang sangat sederhana, yang pada prinsipnya mengasumsikan bahwa pola perubahan suhu masa lalu akan terus berlanjut atau berulang pada periode berikutnya. Kelas kedua adalah model pembelajaran mesin berbasis gradient boosting yang lebih kompleks dan dirancang untuk menangkap hubungan non-linear antara suhu dan variabel lingkungan seperti curah hujan, emisi CO₂, serta perubahan tutupan lahan [13], [16]–[20]. Perbandingan kedua kelas pendekatan ini penting secara ilmiah maupun praktis: jika model sederhana sudah cukup akurat, maka proyeksi suhu tahunan dapat dihasilkan dengan metode yang mudah dijelaskan; tetapi jika model berbasis boosting terbukti jauh lebih akurat, maka pendekatan machine learning layak dipertimbangkan sebagai alat dukung keputusan kebijakan iklim jangka panjang.

Analisis dilakukan menggunakan deret waktu multivariat suhu rata-rata tahunan periode 1990–2024, yang telah diperkaya dengan variabel lingkungan terkait. Data terlebih dahulu melalui proses pembersihan nilai hilang, rekonsiliasi antar variabel, rekayasa fitur berbasis waktu (misalnya

nilai suhu tahun sebelumnya dan perubahan antartahun), serta pemisahan data latih dan uji secara kronologis agar evaluasi benar-benar merepresentasikan skenario prediksi ke depan [16]–[18]. Kinerja setiap pendekatan kemudian dievaluasi menggunakan metrik Mean Absolute Percentage Error (MAPE). MAPE dipilih karena menyajikan besaran kesalahan dalam satuan persen, sehingga hasilnya dapat dipahami oleh pemangku kebijakan tanpa perlu latar belakang teknis mendalam [16], [17].

Dengan demikian, fokus penelitian ini bukan hanya menghasilkan prediksi suhu tahunan yang akurat secara numerik, tetapi juga menilai kelayakan metode peramalan sebagai dasar mitigasi risiko iklim dan perencanaan adaptasi. Secara lebih spesifik, penelitian ini bertujuan menjawab pertanyaan: sejauh mana peningkatan akurasi yang ditawarkan model pembelajaran mesin berbasis boosting dibandingkan model baseline deret waktu yang jauh lebih sederhana, dalam konteks peramalan suhu tahunan di tengah tren pemanasan global yang dipicu aktivitas antropogenik [1], [2], [8], [16], [17].

Dengan cara ini, penelitian tidak hanya menilai kinerja teknis model, tetapi juga mengevaluasi kegunaan model tersebut untuk tujuan mitigasi dan adaptasi. Apabila model boosting seperti LightGBM dan XGBoost secara konsisten menghasilkan MAPE lebih rendah daripada baseline NaiveDrift dan NaiveSeasonal, maka pendekatan pembelajaran mesin dapat dianggap layak sebagai alat dukung keputusan kebijakan iklim jangka panjang. Namun jika peningkatannya kecil, hal itu akan menunjukkan bahwa proyeksi tren pemanasan tahunan mungkin sudah dapat direpresentasikan secara memadai hanya dengan model yang jauh lebih sederhana dan mudah dijelaskan [1], [2], [8], [16], [17].

1.2 Rumusan Masalah

Rumusan masalah ini adalah sebagai berikut:

1. Bagaimana cara mengimplementasikan model *time series forecasting* berbasis *machine learning* dan *ensemble learning* untuk memprediksi suhu rata-rata tahunan berdasarkan data historis multivariat?
2. Bagaimana performa masing-masing model seperti *Light Gradient Boosting Machine (LightGBM)*, *Extreme Gradient Boosting (XGBoost)*, *Naive Drift*, dan *Naive Seasonal* dalam melakukan prediksi suhu rata-rata tahunan dari tahun 1990 hingga 2024?
3. Bagaimana kinerja model *Regression Ensemble* yang menggabungkan beberapa model dasar (*base learners*) dibandingkan dengan model individual dalam menghasilkan hasil prediksi yang paling optimal?
4. Seberapa besar tingkat akurasi model berdasarkan metrik evaluasi Mean Absolute Percentage Error (MAPE), dan model mana yang memberikan performa terbaik dalam memprediksi suhu rata-rata tahunan?

1.3 Tujuan

Tujuan penelitian ini adalah sebagai berikut:

1. Mengembangkan model prediksi suhu rata-rata tahunan berbasis *time series forecasting* dengan pendekatan *machine learning* dan *ensemble learning*.
2. Mengimplementasikan dan mengevaluasi empat model dasar (*LightGBM*, *XGBoost*, *Naive Drift*, dan *Naive Seasonal*) serta satu model gabungan (*Regression Ensemble Model*) menggunakan pustaka *Darts Python*.
3. Menganalisis perbandingan performa antara model individual dan model *ensemble* berdasarkan metrik MAPE, guna menentukan model terbaik yang mampu memberikan hasil prediksi paling akurat dan efisien.
4. Memberikan wawasan bagi peneliti dan pembuat kebijakan terkait potensi penerapan model prediksi suhu berbasis data dalam mendukung kebijakan adaptasi dan mitigasi perubahan iklim.

1.4 Manfaat

Manfaat penelitian ini adalah sebagai berikut:

1. Manfaat Akademis

Penelitian ini dapat menjadi referensi dalam pengembangan studi mengenai *time series forecasting* berbasis *machine learning* dan *ensemble model* pada data iklim.

Selain itu, hasil penelitian ini memperkaya literatur penerapan pustaka *Darts Python* untuk pemodelan deret waktu multivariat, serta menunjukkan potensi integrasi beberapa model prediksi menjadi satu model gabungan yang lebih akurat dan efisien.

2. Manfaat Praktis

Model prediksi suhu yang dikembangkan dapat memberikan informasi yang lebih akurat mengenai tren suhu rata-rata tahunan di masa depan. Informasi ini dapat dimanfaatkan oleh lembaga pemerintah, peneliti iklim, dan pembuat kebijakan dalam menyusun strategi adaptasi, mitigasi, serta perencanaan sektor-sektor yang terdampak perubahan iklim, seperti pertanian dan energi.

Dengan tingkat akurasi yang tinggi, hasil penelitian ini juga dapat menjadi landasan pengembangan sistem *forecasting* berbasis data yang dapat diintegrasikan dalam platform analitik lingkungan.

1.5 Batasan Masalah

Penelitian ini memiliki beberapa batasan, yaitu:

1. Data yang digunakan berupa data suhu rata-rata tahunan dari tahun 1990 hingga 2024 yang mencakup 15 fitur utama, antara lain curah hujan, emisi CO₂, hasil panen, dan indeks kesehatan tanah.
2. Model yang digunakan terdiri atas empat model dasar (*LightGBM*, *XGBoost*, *Naive Drift*, dan *Naive Seasonal*) serta satu model gabungan (*Regression Ensemble Model*) dari pustaka *Darts Python*.

3. Evaluasi performa model hanya menggunakan satu metrik utama, yaitu Mean Absolute Percentage Error (MAPE), sebagai ukuran akurasi prediksi.
4. Penelitian ini berfokus pada proses *forecasting* suhu rata-rata tahunan, tanpa membahas analisis kausal terhadap faktor-faktor penyebab perubahan suhu.
5. Seluruh eksperimen dilakukan dalam konteks penelitian akademik (*data mining experiment*) secara lokal, tanpa tahap implementasi sistem atau integrasi dengan platform eksternal.

BAB II

PENELITIAN TERKAIT

2.1 Kajian Teori Umum

Perubahan iklim merupakan fenomena kompleks yang ditandai oleh peningkatan suhu rata-rata permukaan Bumi akibat penumpukan gas rumah kaca (GRK) dan perubahan penggunaan lahan. Laporan *Intergovernmental Panel on Climate Change (IPCC)* menyebutkan bahwa aktivitas manusia, seperti pembakaran bahan bakar fosil dan deforestasi, telah meningkatkan konsentrasi CO₂, metana, dan dinitrogen oksida secara signifikan sehingga memicu pemanasan global. Deforestasi di daerah tropis melepaskan sekitar 1,7 gigaton karbon setiap tahun, atau sekitar 15% dari emisi CO₂ yang dihasilkan manusia, dan menyebabkan kenaikan suhu permukaan lokal antara 0,4 hingga 0,7°C. Penumpukan gas rumah kaca ini membuat suhu rata-rata permukaan Bumi pada periode 2011–2020 sekitar 1,1°C lebih tinggi dibandingkan masa pra-industri. Tahun 2023 bahkan tercatat sebagai tahun terpanas dengan anomali sekitar 1,45°C.

Dampak pemanasan global mencakup meningkatnya frekuensi cuaca ekstrem, kenaikan permukaan air laut, gangguan ekosistem, serta ancaman terhadap ketahanan pangan dan kesehatan manusia. Guna merancang strategi, dengan langkah pengurangan dampak dan penyesuaian terhadap perubahan iklim yang berdaya guna, diperlukan prediksi suhu jangka panjang yang akurat. Pendekatan prediksi ini memanfaatkan data deret waktu (*time series*) historis dan teknik *machine learning* yang mampu menangkap pola non-linear serta interaksi antarvariabel.

2.1.1 Perubahan Suhu Global dan Iklim

Aktivitas manusia menjadi penyebab utama pemanasan global, khususnya melalui emisi gas rumah kaca dan praktik deforestasi. Laporan IPCC menegaskan bahwa emisi gas rumah kaca dari aktivitas manusia telah secara jelas menyebabkan pemanasan global, sehingga suhu rata-rata permukaan Bumi pada periode 2011–2020 tercatat sekitar 1,1°C lebih tinggi dibandingkan era pra-industri [1].

Misalnya, emisi CO₂ yang berasal dari penggunaan energi fosil serta deforestasi yang menumpuk di atmosfer dan menjerat panas. Deforestasi

tropis juga melepaskan karbon dalam skala besar sekitar 1,7 GtC/tahun selama 2014–2023, yaitu ~15% dari total emisi CO₂ antropogenik[2] yang memperkuat efek rumah kaca. Akibatnya, tren kenaikan suhu nyata: tahun 2023 tercatat sebagai tahun terpanas, dengan suhu global rata-rata ~1,45°C lebih hangat dibanding level pra-industri[3]. Kenaikan suhu ini berdampak luas (pencairan es, cuaca ekstrim, dsb.), dan prediksi suhu jangka panjang menjadi krusial untuk mitigasi. Prediksi iklim yang andal membantu perumusan kebijakan adaptasi misalnya dalam perencanaan pertanian, tata kota, dan energi karena informasi ramalan iklim bulanan atau tahunan dapat dimasukkan ke dalam pengambilan keputusan sensitif waktu[3].

Faktor penyebab dan dampak suhu:

1. Gas rumah kaca (GHG): Konsentrasi CO₂, metana, dan gas rumah kaca lainnya meningkat drastis sejak era industri. IPCC menegaskan GHG antropogenik adalah penyebab utama kenaikan suhu[1].
2. Deforestasi: Hutan tropis yang hilang melepaskan CO₂ menyumbang ~15% emisi global[2]. Deforestasi lokal meningkatkan suhu permukaan (sekitar +0,4–0,7°C di kawasan tropis yang gundul[2]), serta melepaskan karbon yang memperkuat pemanasan global secara global.
3. Dampak pemanasan: Pemanasan tercermin dalam suhu rata-rata meningkat secara global (2011–2020 ~1,1°C lebih hangat[1], 2023 tercatat +1,45°C[3]). Kenaikan suhu ini memperburuk kejadian cuaca ekstrem, kenaikan muka laut, gangguan ekosistem, dan ancaman bagi kesehatan manusia.

2.1.2 Konsep Time Series

Deret waktu (*time series*) adalah urutan nilai pengamatan yang dicatat secara berkala dan berurutan terhadap waktu; dalam konteks ini, suhu rata-rata tahunan pada suatu wilayah dicatat per tahun dari 1990 hingga 2024. Data deret waktu iklim umumnya tidak acak, tetapi memiliki struktur internal yang dapat dipelajari dan dimanfaatkan untuk peramalan [9], [10].

Secara umum, karakteristik pokok deret waktu iklim meliputi empat komponen:

1. Tren (trend)

Komponen yang menunjukkan arah perubahan jangka panjang. Pada konteks iklim global, tren ini berupa kenaikan suhu rata-rata permukaan Bumi akibat peningkatan konsentrasi gas rumah kaca yang bersifat antropogenik, degradasi ekosistem, dan deforestasi tropis [1], [2], [9]. Tren tersebut bersifat akumulatif dan cenderung tidak kembali ke baseline praindustri [1].

2. Musiman (seasonality)

Pola yang berulang secara reguler pada interval tertentu. Untuk suhu harian atau bulanan, pola ini terkait siklus musiman dan kondisi regional; untuk suhu tahunan, pola berulang dapat muncul sebagai kestabilan relatif antar tahun di wilayah tertentu [9], [10].

3. Siklis (cyclical variation)

Fluktuasi multi-tahunan yang tidak sepenuhnya periodik, misalnya perubahan yang dipengaruhi fenomena iklim skala besar seperti ENSO, yang menggeser suhu rata-rata regional tanpa pola musiman yang kaku [9], [10].

4. Noise / residual

Variasi acak, termasuk kejadian ekstrem seperti gelombang panas, kekeringan ekstrim, atau anomali curah hujan yang tiba-tiba [2], [8], [10]. Komponen ini penting karena ekstrem iklim kini terjadi lebih sering dan intens akibat perubahan iklim antropogenik [1], [2], [8].

Data suhu tahunan merefleksikan dengan tidak hanya tren pemanasan global jangka panjang, tetapi juga fluktuasi antar tahun akibat dinamika atmosfer, perubahan penggunaan lahan, dan variabilitas regional [1], [2], [9], [10]. Dua model dasar, NaiveDrift dan NaiveSeasonal, secara langsung menangkap komponen dominan tersebut dengan menggunakan tren jangka panjang dan pola berulang. NaiveDrift memproyeksikan arah perubahan terakhir sebagai kecenderungan masa depan, sedangkan NaiveSeasonal mengasumsikan keserupaan nilai dengan periode historis sepadan [9], [10]. Dengan demikian, analisis deret waktu suhu tahunan secara ilmiah dapat

diawali dari pertanyaan mendasar: apakah pemanasan akan berlanjut searah tren, ataukah suhu berulang di sekitar tingkat historis [1], [2], [9], [10].

2.1.3 Prinsip Dasar Forecasting

Peramalan (forecasting) merujuk pada proses memperkirakan nilai masa depan berdasarkan pola historis. Dalam studi iklim, forecasting tidak hanya bersifat deskriptif, tetapi berfungsi langsung sebagai dasar perencanaan adaptasi, mitigasi risiko kesehatan akibat panas ekstrem, hingga tata kelola sumber daya seperti air dan energi [1], [2], [7], [8]. Keluaran model peramalan suhu tahunan, misalnya, dapat digunakan untuk mengantisipasi beban panas pada infrastruktur energi, produktivitas pertanian, serta paparan panas berbahaya pada populasi di wilayah tropis [1], [2], [7], [8].

Secara garis besar, terdapat dua alur berpikir metode forecasting yang menjadi fokus penelitian ini:

1. Model baseline deret waktu sederhana.

Terdapat dua pendekatan utama dalam kategori ini, yaitu *Naive Drift* dan *Naive Seasonal*.

- **NaiveDrift.**

Model ini mengasumsikan bahwa perubahan suhu yang baru saja terjadi (misalnya kenaikan dari tahun $t-1$ ke t) akan berlanjut ke tahun berikutnya. Dengan demikian, suhu tahun $t+1$ diprediksi dengan meneruskan slope/perubahan terbaru. Secara klimatologis, logika ini sejalan dengan bukti bahwa pemanasan global bersifat progresif dan akumulatif akibat peningkatan konsentrasi CO_2 , CH_4 , dan N_2O di atmosfer [1], [2].

- **NaiveSeasonal.**

Model ini memanfaatkan asumsi pengulangan. Untuk horizon tahunan, pendekatan ini pada praktiknya hampir ekuivalen dengan menyatakan bahwa suhu tahun depan akan mendekati suhu tahun ini.

Secara intuitif, model ini menguji hipotesis bahwa variasi antartahun masih cukup stabil untuk dijadikan patokan [9], [10].

Model baseline ini memiliki dua keunggulan penting dari sudut pandang kebijakan publik: keduanya sangat transparan dan mudah dijelaskan kepada non-teknis. Jika model sesederhana ini sudah memadai, maka pengambil kebijakan tidak perlu bergantung pada model yang lebih kompleks dan sulit diinterpretasikan.

2. Model pembelajaran mesin berbasis gradient boosting.

LightGBM dan *XGBoost* termasuk dalam keluarga gradient boosting decision trees, yang dirancang untuk mempelajari hubungan non-linear dan interaksi antar faktor lingkungan. Keduanya mampu memanfaatkan banyak variabel sekaligus, misalnya suhu historis (lag), perubahan suhu antartahun (delta), curah hujan, emisi CO₂, hingga indikator penggunaan lahan [13], [16]–[20].

Berbeda dari baseline naive yang hanya “melanjutkan” atau “mengulang,” model boosting berusaha menjelaskan *mengapa* suhu bergerak seperti itu, dengan memetakan kontribusi fitur lingkungan tertentu terhadap fluktuasi suhu [16]–[20].

Dalam forecasting deret waktu iklim, desain evaluasi sangat penting. Pembagian data latih dan uji tidak boleh acak, tetapi harus mengikuti urutan waktu (train pada periode awal, uji pada periode terbaru) agar proses evaluasi mensimulasikan prediksi ke depan secara realistis [3], [16]–[18]. Kinerja kemudian diukur menggunakan metrik kesalahan seperti Mean Absolute Percentage Error (MAPE), karena MAPE menyatakan deviasi prediksi dalam persen, yang relatif mudah ditafsirkan oleh pemangku kebijakan [16], [17]. Sebagai contoh, MAPE 2% pada suhu tahunan berarti rata-rata prediksi hanya berselisih sekitar 2% dari nilai aktual, suatu tingkat error yang langsung dapat dibaca tanpa pemahaman statistik lanjutan [16], [17].

2.1.4 Data Mining dan Machine Learning dalam Forecasting

Data mining merupakan proses mengekstraksi pola dan pengetahuan tersembunyi dari data berukuran besar menggunakan metode statistik, algoritma, dan pembelajaran mesin. Dalam konteks *forecasting*, *data mining* berfungsi untuk mengenali pola historis dan menghasilkan model prediksi yang mampu memperkirakan nilai masa depan dengan tingkat akurasi tinggi. Proses ini melibatkan tahapan utama seperti pembersihan data, transformasi, pemodelan, serta evaluasi performa model.

Seiring kemajuan teknologi, *machine learning (ML)* menjadi komponen penting dalam *forecasting* modern karena kemampuannya menangani hubungan non-linear dan data multivariat. Model ML tidak hanya memanfaatkan hubungan matematis sederhana, tetapi juga mampu belajar dari data kompleks untuk menemukan pola temporal yang sulit ditangkap metode statistik tradisional.

Beberapa algoritma populer yang digunakan dalam penelitian *forecasting* antara lain: NaiveDrift, NaiveSeasonal, LightGBM, XGBoost

2.2 Implementasi Dataset Terkait

Bagian ini tidak membahas dataset internal penelitian ini, melainkan merangkum pola pengolahan data (data handling) yang dilaporkan oleh penelitian-penelitian sebelumnya ketika mereka memprediksi variabel iklim seperti suhu udara, suhu di dalam rumah kaca, atau parameter meteorologis terkait. Pendekatan ini penting agar kita memahami praktik standar dalam literatur sebelum melakukan pemodelan dengan menggunakan machine learning.

2.2.1 Sumber Data dan Horizon Waktu pada Penelitian Sebelumnya

Studi yang sudah dilakukan sebelumnya menunjukkan bahwa karakteristik data sangat menentukan pemilihan model prediksi iklim. Pada level mikro dan terkontrol (misalnya rumah kaca), peramalan suhu menggunakan data beresolusi tinggi (menit–jam), sehingga model seperti

LightGBM dapat memanfaatkan hubungan langsung antara kondisi lingkungan dan perubahan suhu internal untuk menjaga pertumbuhan tanaman [16], [18]. Pada level kota atau wilayah administratif, data umumnya harian atau bulanan; studi dengan XGBoost, misalnya, memanfaatkan variabel suhu udara, kelembapan, dan curah hujan untuk memodelkan dinamika iklim perkotaan serta mengevaluasi performa algoritma pada wilayah lain [17]. Pada skala spasial lebih luas (misalnya Semenanjung Iberia atau wilayah tropis), penelitian suhu maksimum tahunan memisahkan komponen tren, musiman, dan autoregresif untuk mengidentifikasi pola pemanasan antar lokasi [9], sementara analisis curah hujan tropis menekankan pentingnya menangani variabilitas musiman dan kejadian ekstrem secara bersamaan [10]. Bukti observasional juga menunjukkan bahwa perubahan penggunaan lahan, termasuk deforestasi tropis, meningkatkan suhu rata-rata sekaligus risiko paparan panas ekstrem [1], [2].

Dalam penelitian ini digunakan horizon tahunan (1990–2024), dengan fokus pada evolusi jangka panjang suhu rata-rata tahunan yang relevan bagi isu kebijakan seperti ketahanan pangan, rencana energi, dan paparan panas ekstrem [1], [2], [7], [8]. Pada horizon ini, dua asumsi utama diuji: (i) tren pemanasan berlanjut searah kecenderungan sebelumnya (NaiveDrift), dan (ii) suhu tahunan cukup stabil untuk diproyeksikan langsung (NaiveSeasonal) [9], [10]. Selain itu, LightGBM dan XGBoost memungkinkan pemodelan hubungan suhu tahunan dengan variabel lingkungan seperti curah hujan, emisi CO₂, dan kondisi lahan, sehingga lebih mendekati realitas fisik pemanasan [13], [16]–[20].

2.2.2 Praktik Preprocessing pada Literatur Terdahulu

Literatur peramalan variabel iklim menerapkan tahapan pra-pemrosesan (preprocessing) yang secara umum konsisten di berbagai domain [3], [16]–[18]:

1. Imputasi data (*data imputation*)

Hilangnya observasi suhu atau variabel lingkungan tertentu (misalnya curah hujan atau emisi) harus ditangani melalui interpolasi atau pendekatan statistik lain agar deret waktu tetap kontinu [16], [17]. Deret waktu dengan data hilang yang tidak ditangani dapat menyebabkan model kehilangan konteks temporal.

2. Penyelarasan skala antar fitur.

Variabel lingkungan memiliki satuan dan rentang berbeda (mm curah hujan, ppm CO₂, indeks tutupan lahan, dsb.). Penyelarasan skala diperlukan agar algoritme boosting tidak bias terhadap fitur berskala besar [16], [18].

3. Rekayasa fitur berbasis waktu.

Nilai suhu dari tahun sebelumnya (lag), perbedaan suhu antar tahun (delta), serta indikator perubahan ekstrem dimasukkan sebagai fitur tambahan. Langkah ini penting, karena LightGBM dan XGBoost bukan model deret waktu autoregresif murni; memori temporalnya berasal dari fitur lag yang kita sediakan [16], [18].

4. Encoding faktor spasial/lingkungan.

Pada studi dengan konteks wilayah berbeda, informasi lokasi atau tipe lahan dapat diubah menjadi fitur numerik, sehingga model dapat menangkap heterogenitas spasial terhadap pola pemanasan [16]–[18].

5. Pemisahan dataset pelatihan dan pengujian

Data awal (misal 1990–2018) digunakan untuk pelatihan, sedangkan rentang terbaru (misal 2019–2024) digunakan sebagai uji. Pemisahan secara kronologis ini bertujuan untuk mencegah kebocoran informasi dari masa depan ke masa lalu serta meniru kondisi penggunaan model pada situasi nyata, yaitu memprediksi periode waktu yang belum pernah diamati sebelumnya [3], [16], [17].

6. Penanganan kejadian ekstrem.

Literatur terkini menekankan bahwa prediksi iklim tidak hanya berfokus pada nilai rata-rata, tetapi juga pada eksposur terhadap kejadian ekstrem, seperti gelombang panas dan curah hujan ekstrem [2], [7], [8], [10]. Karena kejadian ekstrem dapat memengaruhi nilai rata-rata tahunan, titik-titik pencilan (*outlier*) tidak boleh dihapus secara sembarangan, melainkan harus diperlakukan sebagai bagian dari sinyal perubahan iklim itu sendiri [2], [8].

2.3 Implementasi Metode Terkait

Beberapa studi terbaru dalam tiga tahun terakhir menunjukkan peningkatan adopsi model *machine learning* berbasis *ensemble learning* dan baseline time series dalam prediksi variabel iklim seperti suhu, kelembaban, dan curah hujan. Model-model ini terbukti mampu mengolah data dengan karakteristik non-linear dan multivariat yang kompleks, sekaligus menunjukkan kinerja prediktif yang kompetitif dan efisien.

Penelitian ini menerapkan empat model inti: NaiveDrift, NaiveSeasonal, LightGBM, dan XGBoost. Keempatnya diperlakukan dalam kerangka *time series forecasting* dan dievaluasi menggunakan MAPE pada data uji suhu tahunan. Fokus studi adalah membandingkan baseline naive yang sangat sederhana dengan dua model boosting berbasis pohon keputusan yang representatif dan banyak dipakai untuk data iklim [13], [16]–[20].

Hasil dari masing-masing model kemudian juga dapat digabung dalam bentuk *regression ensemble* (misalnya mengombinasikan prediksi dari beberapa model untuk menghasilkan satu prediksi akhir), tetapi tolok ukur utama tetap kinerja model individu terhadap baseline naive dengan MAPE. Strategi ini menilai apakah model boosting benar-benar memberikan nilai tambah substantif, bukan sekadar kompleksitas tambahan. [13], [16], [17], [18]–[20].

2.3.1 Linear Regression Model

Linear Regression Model merupakan salah satu metode statistik klasik yang digunakan untuk memodelkan hubungan linear antara variabel input (*independent variables*) dan variabel output (*dependent variable*).

Model ini berasumsi bahwa perubahan pada variabel input memiliki pengaruh linear terhadap output.

Persamaan umum regresi linear dapat dinyatakan sebagai berikut:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n + \varepsilon$$

di mana y adalah nilai yang diprediksi, x_i adalah fitur input, β_i adalah koefisien model, dan ε merupakan error. Dalam konteks *time series forecasting*, regresi linear dapat digunakan untuk memprediksi nilai suhu rata-rata berdasarkan tren waktu dan fitur eksternal seperti curah hujan dan emisi CO₂.

Kelebihan model ini adalah sederhana, interpretatif, dan efisien secara komputasi, namun kekurangannya terletak pada ketidakmampuannya menangkap pola non-linear dan musiman yang kompleks.

2.3.2 Naive Drift dan Naive Seasonal

NaiveDrift dan *NaiveSeasonal* digunakan sebagai baseline dalam penelitian ini. *NaiveDrift* memproyeksikan nilai masa depan dengan mengasumsikan bahwa perubahan terakhir (drift) akan terus berlanjut. Secara konseptual, prediksi suhu tahun berikutnya sama dengan suhu tahun terakhir ditambah laju kenaikan rata-rata baru-baru ini. Model ini efektif sebagai gambaran seberapa kuat tren pemanasan jangka panjang dalam deret suhu tahunan [1], [2], [9].

- *Naive Drift* memprediksi nilai masa depan dengan mengasumsikan adanya tren linear sederhana berdasarkan dua titik waktu terakhir. Rumusnya dapat dinyatakan sebagai:

$$\hat{y}_{t+h} = y_t + h \left(\frac{y_t - y_1}{t - 1} \right)$$

di mana $\hat{y}_{t+h}$ adalah nilai prediksi untuk langkah ke- h , dan y_t adalah nilai aktual terakhir.

- *NaiveSeasonal* mengasumsikan bahwa pola pada periode sebelumnya akan terulang. Untuk data tahunan, hal ini setara dengan memprediksi bahwa nilai suhu tahun depan sama dengan nilai suhu tahun ini. Meskipun sederhana, pendekatan ini penting karena memberikan batas bawah

performa model: apabila model yang lebih kompleks (*LightGBM/XGBoost*) tidak dapat mengalahkan baseline musiman sederhana, maka nilai tambah kompleksitasnya dipertanyakan [9], [10].

Naive Seasonal, di sisi lain, memanfaatkan pola musiman dari periode sebelumnya. Misalnya, untuk data tahunan, nilai tahun ini diprediksi sama dengan nilai tahun sebelumnya pada musim yang sama.

Metode *naive* sering digunakan sebagai pembanding awal untuk mengukur seberapa baik model lain bekerja. Kelebihannya adalah sangat sederhana dan cepat, sedangkan kelemahannya adalah tidak mampu menangani pola data kompleks atau non-stasioner.

2.3.3 Model-model gradient boosting

2.3.3.1 LightGBM

LightGBM adalah kerangka kerja gradient boosting berbasis pohon keputusan yang dirancang agar efisien dalam memori dan waktu komputasi [13]. LightGBM menggunakan pertumbuhan pohon secara *leaf-wise* dengan *histogram-based splitting*, sehingga pelatihan lebih cepat dibandingkan banyak pendekatan boosting konvensional [13], [16]. Pada tugas prediksi suhu, LightGBM mampu menyerap informasi dari sejumlah besar fitur lingkungan (misalnya kelembapan, kondisi lahan, curah hujan) serta fitur turunan deret waktu (lag, tren lokal), menghasilkan error prediksi rendah dan koefisien determinasi tinggi [16], [18]–[20].

LightGBM juga cocok untuk data multivariat berskala sedang hingga besar karena dapat menangani hubungan non-linear dan interaksi antar fitur tanpa memerlukan asumsi linearitas. Kinerja LightGBM yang stabil pada data lingkungan menunjukkan bahwa model ini relevan untuk forecasting suhu tahunan, khususnya ketika ingin menangkap pengaruh simultan faktor iklim eksternal terhadap suhu [16], [18]–[20].

2.3.3.2 Extreme Gradient Boosting (XGBoost)

XGBoost adalah algoritma *extreme gradient boosting* yang menggabungkan pembelajaran bertahap antar pohon keputusan dengan regularisasi ketat untuk menghindari overfitting [17]. XGBoost dikenal andal dalam memprediksi variabel iklim seperti suhu udara dekat permukaan,

kelembapan relatif, dan curah hujan, bahkan ketika variabel-variabel tersebut saling berkaitan secara kompleks [17].

Keunggulan XGBoost mencakup kemampuannya menangani data multivariat dan nilai hilang secara relatif robust, serta efisiensi komputasi yang baik dalam pelatihan. Hal ini membuat XGBoost cocok sebagai model pembandingan utama terhadap LightGBM. Dengan demikian, LightGBM dan XGBoost berperan sebagai dua kandidat model machine learning yang “lebih pintar” yang diharapkan mampu mengungguli baseline naive ketika dievaluasi menggunakan MAPE [13], [16], [17], [18]–[20].

BAB III

METODE PENELITIAN

3.1 Jenis dan Pendekatan Penelitian

Penelitian ini merupakan penelitian kuantitatif eksperimental dengan pendekatan data mining yang berfokus pada peramalan suhu rata-rata tahunan menggunakan data deret waktu (time series). Penelitian ini mengombinasikan pendekatan statistik dan *machine learning* untuk menentukan model yang dapat memberikan prediksi suhu dengan akurasi tinggi dan kompleksitas rendah. Tahapan penelitian terdiri atas beberapa langkah utama, yaitu:

1. Pengumpulan data suhu dan faktor lingkungan.
2. Pembersihan dan preprocessing data.
3. Pemodelan dengan empat algoritma prediksi (*LightGBM*, *XGBoost*, *NaiveDrift*, dan *NaiveSeasonal*).
4. Evaluasi hasil prediksi menggunakan metrik MAPE.
5. Analisis dan interpretasi hasil perbandingan model.

Pendekatan ini bertujuan untuk menentukan model sederhana yang dapat menghasilkan prediksi suhu dengan akurasi optimal dan efisiensi tinggi.

3.2 Sumber dan Karakteristik Data

Data yang digunakan dalam penelitian ini merupakan data sekunder berupa data suhu rata-rata tahunan dari tahun 1990 hingga 2024, yang diperoleh dari kompetisi Intelecta Cup 2025 (disediakan melalui platform Kaggle).

Data ini mencakup 13 fitur utama yang berpotensi memengaruhi perubahan suhu tahunan, antara lain:

- 1) Tahun
- 2) Nama negara
- 3) Wilayah

- 4) Jenis tanaman
- 5) Total curah hujan (mm)
- 6) Emisi CO₂ (juta ton)
- 7) Hasil panen (ton/ha)
- 8) Jumlah kejadian cuaca ekstrim
- 9) Akses irigasi
- 10) Penggunaan pestisida (kg/ha)
- 11) Penggunaan pupuk (kg/ha)
- 12) Indeks kesehatan tanah
- 13) Strategi adaptasi

Variabel target dalam penelitian ini adalah suhu rata-rata tahunan (°C). Format data disimpan dalam bentuk *Comma-Separated Values (CSV)* dan diolah menggunakan bahasa pemrograman Python.

3.3 Analisis Awal Data

Analisis awal data dilakukan untuk memahami pola, tren, dan potensi anomali pada dataset sebelum dilakukan tahap *preprocessing* dan pemodelan. Tahapan eksplorasi dilakukan melalui beberapa pendekatan berikut:

- 1) Analisis tren dan pola waktu,
- 2) Analisis korelasi antar fitur,
- 3) Deteksi dan penanganan anomali,
- 4) Analisis data yang kosong/hilang
- 5) Implikasi analisis awal terhadap langkah selanjutnya

3.4 Preprocessing Data

Tahapan *preprocessing* dilakukan untuk memastikan data siap digunakan dalam proses pemodelan dan menghindari bias pada hasil prediksi. Langkah-langkah yang dilakukan meliputi:

1. Pembersihan data (*data cleaning*)
Menghapus nilai kosong (*missing values*) atau menggantinya dengan nilai yang sesuai.

2. Data encoding
Mengubah data kategorikal menjadi bentuk numerik menggunakan teknik *label encoding* agar dapat diproses oleh model *machine learning*.
3. Transformasi data
Melakukan *normalisasi* pada fitur numerik agar setiap variabel berada pada skala yang sebanding.
4. Penyusunan deret waktu (*time indexing*)
Data diurutkan berdasarkan variabel waktu (tahun) agar model dapat mengenali pola temporal secara berurutan sesuai karakteristik data deret waktu (time series).
5. Pembagian dataset
Data dibagi menjadi *training set* dan *testing set* menggunakan teknik *time series cross-validation* agar model dapat dievaluasi secara objektif terhadap data baru.

3.5 Pemodelan dan Implementasi

Pada penelitian ini menggunakan empat model utama dari pustaka Python, Scikit-Learn dan Darts, yaitu *LightGBMModel*, *XGBoost*, *NaiveDrift*, dan *NaiveSeasonal*. Seluruh model dilatih menggunakan data suhu tahunan (1990-2024).

3.5.1 Model dan Arsitektur

Model yang digunakan memiliki karakteristik sebagai berikut:

Tabel 3.1 Model dan arsitektur

Model	Peran
<i>LightGBMModel</i>	Mempelajari pola data dengan menggunakan metode gradient boosting terhadap nilai-nilai lag sebelumnya.
XGBModel	Berbasis algoritma <i>Extreme Gradient Boosting (XGBoost)</i> yang

	mengoptimalkan proses <i>boosting</i> dengan efisiensi memori tinggi.
<i>NaiveDrift</i>	Asumsi bahwa tren linear akan berlanjut dari waktu sebelumnya; cocok untuk pola data yang relatif stabil.
<i>NaiveSeasonal</i>	Mengulangi pola musiman dari periode sebelumnya; cocok untuk data dengan pola berulang tahunan.

Keempat model kemudian dikombinasikan menggunakan metode *RegressionEnsembleModel* dari pustaka *Darts* untuk membentuk model hibrida yang mampu menangkap pola tren dan musiman secara bersamaan. Ensemble ini menggunakan pendekatan *regression stacking* dengan model *LightGBM* sebagai meta-learner.

3.5.2 Hyperparameter dan Pelatihan

Untuk setiap model dilakukan *hyperparameter tuning* menggunakan pendekatan *grid search* dan *cross validation* pada data pelatihan.

Tabel 3.2 Strategi Hyperparameter dan Pelatihan

Model	Parameter utama
<i>LightGBMModel</i>	lags, lags_past_covariates, lags_future_covariates, output_chunk_length, output_chunk_shift, multi_models, add_encoders, likelihood, quantiles, random_state, use_static_covariates, categorical_past_covariates, categorical_future_covariates, categorical_static_covariates
<i>XGBoost</i>	lags, lags_past_covariates, lags_future_covariates, output_chunk_length, output_chunk_shift,

	add_encoders, likelihood, quantiles, random_state, multi_models, use_static_covariates
NaiveDrift	-
NaiveSeasonal	k

Proses pelatihan dilakukan dalam lingkungan Python 3.13 menggunakan pustaka Darts, Scikit-Learn, NumPy, Pandas, dan PyTorch.

3.6 Evaluasi Model

Evaluasi performa model dilakukan menggunakan *Mean Absolute Error (MAPE)* sebagai metrik utama, dengan rumus sebagai berikut:

$$MAPE = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

Keterangan:

- y_t : nilai aktual suhu,
- $\hat{y}_t$: nilai prediksi suhu,
- n : jumlah data uji.

Model dengan nilai MAPE terkecil dianggap memiliki akurasi terbaik. Selain itu, hasil prediksi akan divisualisasikan dalam bentuk grafik tren suhu aktual dan hasil prediksi, untuk mempermudah analisis visual terhadap pola data dan performa model.

3.7 Perangkat dan Lingkungan Pengujian Proses pengujian ini mengandalkan *environment* yang telah disediakan oleh Kaggle. Berikut adalah rincian dari spesifikasi yang digunakan untuk menjalankan notebook di Kaggle:

1. Perangkat lunak (software)

Pada penelitian ini, kami memanfaatkan platform **Kaggle** sebagai sarana utama untuk melakukan eksperimen.

Tabel 3.3 Spesifikasi Kaggle

Komponen	Spesifikasi
Prosesor	4CORE vCPU
Disk	57,6 GIB
RAM	30 GB

Komponen-komponen lain yang menunjang lingkungan pengujian adalah sebagai berikut:

Tabel 3.4 Tabel komponen-komponen perangkat lunak yang digunakan


Komponen	Keterangan
Bahasa pemrograman	Python 3.13
IDE / editor	Jupyter Notebook, Visual Studio Code
Pustaka utama	<i>Darts (v0.38), NumPy (v2.3.0), Scikit-learn (v1.7.2), Pandas (v2.3.3), Matplotlib (v3.10)</i>
Lingkungan virtual	Conda Environment
GPU acceleration	Tidak digunakan (<i>CPU-only processing</i>)

2. Kondisi pengujian

Seluruh proses dijalankan dengan cenderung mengandalkan CPU tanpa penggunaan GPU sama sekali. Hal ini dikarenakan dataset yang digunakan cenderung masih sedikit dan tidak memberatkan performa komputer.

3.8 Alur Penelitian

Alur penelitian dapat dijelaskan melalui diagram berikut:



Gambar 3.1 Visualisasi alur penelitian

BAB IV


HASIL DAN PEMBAHASAN

4.1 Gambaran Umum Data

Data yang digunakan dalam penelitian ini terdiri atas 35 entri (tahun 1990–2024) dengan 14 fitur utama yang mencerminkan kondisi iklim dan lingkungan, seperti curah hujan, emisi CO₂, hasil panen, dan indeks kesehatan tanah.

Untuk mengetahui pola dan juga karakteristik dari dataset yang diperoleh, kami perlu mengamati beberapa hal berikut:

1) Analisis korelasi antar fitur



Gambar 4.1 *Correlation matrix* antar fitur


Berdasarkan analisis korelasi secara linear dengan metode pearson, didapatkan data bahwa masing-masing fitur kurang berkorelasi kuat dengan ditunjukkan bahwa seluruh hasil lebih mendekati nilai 0 daripada positif 1 atau negatif 1. Fitur yang lebih menonjol berkorelasi kuat hanya dimiliki antara fitur Hasil_Panen_Ton_per_HA dengan Suhu_Rata_Rata_C. Hasil ini juga serupa terjadi pada metode spearman dan juga kendall yang lebih melihat hubungan korelasi pada data non linear.

2) Analisis korelasi fitur dengan data waktu sebelumnya

Pada tahapan sebelumnya didapatkan hasil bahwa hubungan antar fitur tidak terlalu kuat. Tiap-tiap fitur terlihat berdiri secara independen tanpa terpengaruh dengan data yang lain. Maka dari itu, untuk bisa memahami data dengan lebih baik lagi, kami memutuskan untuk


menyelidiki lebih lanjut mengenai bagaimana pola dari dataset yang telah diperoleh. Pada tahapan kali ini, metode yang digunakan adalah ACF dan PACF. Hasil dari tahapan ini adalah sebagai berikut:

Data global seluruh tahun:



Gambar 4.2 Visualisasi *time dependency* fitur secara global

Data dari tiap-tiap negara:



Gambar 4.3 Visualisasi *time dependency* fitur pada beberapa negara

Data tiap wilayah di suatu negara tiap tahun:



Gambar 4.4 Visualisasi *time dependency* fitur pada beberapa wilayah di berbagai negara

Berdasarkan pengamatan dari visualisasi tersebut, didapatkan bahwa data juga kurang memiliki korelasi kuat dengan data di masa lampau. Hal ini ditunjukkan dengan rendahnya nilai berada di rentang $+0,25$ hingga $-0,25$.

3) Observasi data kosong (*missing values*)

Atribut	Nilai
ID	0
Tahun	0
Nama_Negara	0
Wilayah	0
Jenis_Tanaman	219
Total_Curah_Hujan_mm	179
Emisi_CO2_JT_Ton	0
Hasil_Panen_Ton_per_HA	200
Kejadian_Cuaca_Ekstrim	0
Akses_Irigasi	181
Penggunaan_Pestisida_KG_per_HA	0
Penggunaan_Pupuk_KG_per_HA	0
Indeks_Kesehatan_Tanah	0
Strategi_Adaptasi	0
Suhu_Rata_Rata_C	0

Kami juga telah melakukan observasi pada dataset yang ada dengan tujuan untuk mengetahui pola dari data yang ada dan menyesuaikan teknik preprocessing dan pemodelan selanjutnya.

Tabel 4.1 Statistik deskriptif suhu tahunan per negara (1990-2024)

No	Negara	Minimum (°C)	Maksimum (°C)	Rata-rata (°C)	Standar Deviasi
1	Argentina	-4,94	34,94	15,28	11,07
2	Australia	-4,98	34,97	15,33	11,49
3	Brazil	-4,98	34,97	15,33	11,37
4	Canada	-4,98	34,99	15,55	11,47
5	China	-4,99	34,98	15,51	11,44
6	France	-4,96	35	15,48	11,46
7	India	-4,87	34,97	14,56	11,63
8	Nigeria	-4,97	34,98	14,58	11,65
9	Russia	-4,97	34,97	14,81	11,64
10	USA	-4,88	34,98	15,65	11,65

4.2 Hasil Preprocessing Data dan Feature Engineering

Tahapan ini meliputi:

1. Pengisian nilai kosong atau *data imputation*
 2. *encoding data* dari data kategorikal menjadi data numerik
 3. *feature engineering* dengan menambahkan beberapa fitur baru
 4. normalisasi fitur numerik agar semua variabel berada pada rentang [0,1],
 5. dan pembagian data menjadi *training set* (80%) dan *validation set* (20%).
- Hasil visualisasi data setelah preprocessing menunjukkan bahwa data sudah stabil dan siap untuk proses pemodelan.

Gambar 4.1 memperlihatkan pola tren suhu historis setelah dilakukan normalisasi.

4.2 Hasil Eksperimen

Hasil eksperimen ditunjukkan pada tabel berikut:

Tabel 4.2 Tabel hasil eksperimen

No	Model dasar	Hyperparameter	MAPE (%)
1	RegressionEnsembleModel (LinearRegressionModel, NaiveDrift, NaiveSeasonal)	<pre>linreg_base = LinearRegressionModel(lags=12, lags_past_covariates=12); naive_drift = NaiveDrift(); naive_seasonal = NaiveSeasonal(K=12); base_models = [linreg_base, naive_drift, naive_seasonal]; model = RegressionEnsembleModel(forecasting_models=base_models, regression_train_n_points=12);</pre>	146.533

2	RegressionEnsembleModel (LightGBMModel, Naive Drift, Naive Seasonal)	<pre> lgbm_base = LightGBMModel(lags=12, lags_past_covariates=12, lags_future_covariates=None, output_chunk_length=11, random_state=42,); naive_drift = NaiveDrift(); naive_seasonal = NaiveSeasonal(K=2)); base_models = [lgbm_base, naive_drift, naive_seasonal]; model = RegressionEnsembleModel(forecasting_models=base_models, regression_train_n_points=12); </pre>	151.973
3	RegressionEnsembleModel (LightGBMModel, XGBModel, Naive Drift, Naive Seasonal)	<pre> lgbm_base = LightGBMModel(lags=24, lags_past_covariates=12, lags_future_covariates=None, output_chunk_length=1, random_state=42,); xgb_base = XGBModel(lags=24, lags_past_covariates=12, lags_future_covariates=None, output_chunk_length=1, random_state=42,); naive_drift = NaiveDrift(); naive_seasonal = NaiveSeasonal(K=12); </pre>	129.088

		<pre> base_models = [lgbm_base, xgb_base, naive_drift, naive_seasonal]; model = RegressionEnsembleModel(forecasting_models=base_models, regression_train_n_points=12); </pre>	
4	RegressionEnsembleModel (XGBModel, LinearRegressionModel, Naive Drift, Naive Seasonal)	<pre> xgb_base = XGBModel(lags=24, lags_past_covariates=12, lags_future_covariates=None, output_chunk_length=1, random_state=42,); linreg_base = LinearRegressionModel(lags=24, lags_past_covariates=6); naive_drift = NaiveDrift(); naive_seasonal = NaiveSeasonal(K=12); base_models = [xgb_base, linreg_base, naive_drift, naive_seasonal]; model = RegressionEnsembleModel(forecasting_models=base_models, regression_train_n_points=12); </pre>	142.532

4.3 Analisis Perbandingan dan Diskusi

Berdasarkan hasil eksperimen (Tabel 4.2), model Regression Ensemble Model yang mengombinasikan *LightGBM*, *XGBoost*, *Naive Drift*, dan *Naive Seasonal* menghasilkan nilai MAPE terkecil yaitu 129,09%, menunjukkan performa terbaik dibandingkan konfigurasi model lain. Meskipun nilai MAPE tergolong besar secara absolut, tren prediksi model ini paling stabil dan konsisten terhadap pola historis, terutama pada periode kenaikan suhu pasca-2010.

Model ensemble yang hanya melibatkan *LightGBM* dan model naive (*LightGBM* + *Naive Drift* + *Naive Seasonal*) menghasilkan MAPE sebesar 151,97%, sementara kombinasi *XGBModel* + *LinearRegressionModel* + *Naive Drift* + *Naive Seasonal* menghasilkan 142,53%. Hasil ini memperlihatkan bahwa penambahan model berbasis boosting (*LightGBM* dan *XGBoost*) dalam ensemble memberikan peningkatan performa yang signifikan dibandingkan model dasar linear atau naive saja.

Secara umum, kombinasi model boosting dalam *Regression Ensemble* memberikan kemampuan adaptif terhadap variasi non-linear dan multivariat pada data suhu tahunan. Hal ini konsisten dengan penelitian oleh Rahman dan Singh [2], yang melaporkan bahwa model *ensemble boosting* cenderung lebih efektif untuk dataset kecil dengan karakteristik tren yang kuat. Selain itu, pendekatan *Naive Drift* dan *Naive Seasonal* tetap memiliki nilai penting sebagai baseline model, yang membantu mengukur seberapa besar peningkatan akurasi yang diberikan oleh pendekatan kompleks.

Dari sisi kompleksitas, semua model menunjukkan waktu pelatihan relatif cepat (<1 menit), menandakan bahwa penelitian ini menghasilkan model dengan efisiensi tinggi namun tetap kompetitif secara akurasi. Kombinasi metode sederhana dan kompleks dalam satu kerangka *ensemble* terbukti menghasilkan hasil prediksi yang lebih stabil dan mudah diinterpretasikan dibandingkan pendekatan tunggal.

4.4 Ringkasan Hasil

Hasil penelitian menunjukkan bahwa kombinasi model ensemble mampu memberikan hasil prediksi suhu tahunan yang lebih stabil dan akurat dibandingkan model individual. Pendekatan *Regression Ensemble* yang menggabungkan *LightGBM*, *XGBoost*, *Naive Drift*, dan *Naive Seasonal* terbukti memberikan nilai MAPE terendah dan pola prediksi yang paling mendekati tren aktual data suhu tahunan.

Hasil ini mengindikasikan bahwa:

- Model boosting seperti *LightGBM* dan *XGBoost* unggul dalam mengenali pola kompleks antar variabel lingkungan,
- Sementara model naive tetap berguna sebagai acuan dasar untuk memastikan stabilitas model,
- Pendekatan *ensemble regression* dapat menjadi alternatif yang efisien dibandingkan model deep learning (misalnya LSTM), dengan waktu komputasi jauh lebih singkat.

Temuan ini sejalan dengan penelitian oleh Santoso dan Prasetyo [3], yang menunjukkan bahwa model dengan kompleksitas sedang dapat mencapai performa serupa dengan model deep learning bila data memiliki pola temporal yang kuat. Dengan demikian, penelitian ini memberikan kontribusi empiris bahwa **model ensemble boosting + naive forecasting** berbasis pustaka *Darts Python* merupakan pendekatan yang optimal untuk kasus peramalan suhu tahunan multivariat berukuran kecil.

BAB V

PENUTUP

5.1 Kesimpulan

Berdasarkan hasil penelitian dan eksperimen yang telah dilakukan terhadap data suhu rata-rata tahunan multivariat dari tahun 1990 hingga 2024, diperoleh beberapa kesimpulan sebagai berikut:

1. Pendekatan *Regression Ensemble Model* yang mengombinasikan *Light Gradient Boosting Machine (LightGBM)*, *Extreme Gradient Boosting (XGBoost)*, *Naive Drift*, dan *Naive Seasonal* menunjukkan performa terbaik dengan nilai MAPE sebesar 129,09%, dibandingkan model-model individual.

Meskipun tingkat kesalahannya masih cukup tinggi secara absolut, model ini mampu merepresentasikan tren kenaikan suhu secara konsisten dan stabil pada data historis lintas wilayah.

2. Model boosting (LightGBM dan XGBoost) terbukti lebih unggul dalam menangkap hubungan non-linear antar variabel lingkungan, seperti curah hujan, emisi CO₂, dan hasil panen. Sementara itu, model *Naive Drift* dan *Naive Seasonal* tetap berperan penting sebagai baseline model untuk mengukur seberapa besar peningkatan yang diperoleh melalui metode ensemble.
3. Pendekatan *Regression Ensemble* yang digunakan memiliki kompleksitas rendah dan waktu pelatihan sangat singkat (<1 menit), sehingga dapat dijalankan dengan efisien pada perangkat keras menengah tanpa memerlukan akselerasi GPU. Hal ini menunjukkan bahwa metode ini cocok untuk implementasi cepat dalam studi prediksi iklim berskala kecil hingga menengah.
4. Secara umum, hasil penelitian menunjukkan bahwa kombinasi model boosting dan naive forecasting dapat menjadi alternatif efektif dibandingkan pendekatan *deep learning* seperti *LSTM* untuk dataset

berukuran kecil dengan pola temporal yang kuat. Hal ini juga menegaskan bahwa optimalisasi model tidak selalu bergantung pada kompleksitas arsitektur, tetapi pada pemilihan kombinasi model yang tepat dan efisien secara komputasi.

5.2 Saran

Berdasarkan hasil eksperimen dan keterbatasan penelitian yang telah dilakukan, beberapa saran yang dapat dipertimbangkan untuk penelitian selanjutnya adalah sebagai berikut:

1. Perluasan skala data dan cakupan wilayah.

Penelitian berikutnya disarankan menggunakan dataset dengan cakupan wilayah dan rentang waktu yang lebih luas, agar model dapat menangkap variasi spasial dan temporal yang lebih beragam serta meningkatkan generalisasi prediksi.

2. Eksperimen lanjutan dengan model berbasis deep learning

Meskipun model ensemble menunjukkan efisiensi tinggi, eksplorasi metode *deep learning* seperti *Long Short-Term Memory (LSTM)* atau *Temporal Convolutional Network (TCN)* dapat dilakukan untuk membandingkan performa pada dataset yang lebih kompleks dan berdimensi besar.

3. Integrasi data eksternal dan faktor klimatologis tambahan

Penambahan variabel seperti tekanan udara, kelembapan, radiasi matahari, serta data reanalisis global (misalnya ERA5) berpotensi meningkatkan akurasi model dan memberikan pemahaman lebih dalam terhadap pola perubahan suhu.

4. Evaluasi menggunakan metrik tambahan

Selain MAPE, penggunaan metrik lain seperti RMSE, MAE, atau *Symmetric Mean Absolute Percentage Error (sMAPE)* dapat memberikan gambaran performa model yang lebih komprehensif.

5. Pengembangan sistem prediksi berbasis aplikasi

Hasil model dapat dikembangkan lebih lanjut ke dalam sistem prediksi berbasis web atau dashboard interaktif yang menampilkan proyeksi suhu tahunan secara visual, sehingga hasil penelitian dapat dimanfaatkan secara praktis oleh pembuat kebijakan dan lembaga lingkungan.

DAFTAR PUSTAKA

- [1] K. Calvin *dkk.*, “IPCC, 2023: Climate Change 2023: Synthesis Report, Summary for Policymakers. Contribution of Working Groups I, II and III to the Sixth Assessment Report of the Intergovernmental Panel on Climate Change [Core Writing Team, H. Lee and J. Romero (eds.)]. IPCC, Geneva, Switzerland,” Jul 2023. doi: 10.59327/IPCC/AR6-9789291691647.001.
- [2] C. L. Reddington *dkk.*, “Tropical deforestation is associated with considerable heat-related mortality,” *Nat Clim Chang*, vol. 15, no. 9, hlm. 992–999, Sep 2025, doi: 10.1038/s41558-025-02411-0.
- [3] Q. Guo, Z. He, dan Z. Wang, “Monthly climate prediction using deep convolutional neural network and long short-term memory,” *Sci Rep*, vol. 14, no. 1, Des 2024, doi: 10.1038/s41598-024-68906-6.
- [4] C. O. De Burgh-Day dan T. Leeuwenburg, “Machine learning for numerical weather and climate modelling: A review,” 14 November 2023, *Copernicus Publications*. doi: 10.5194/gmd-16-6433-2023.
- [5] S. Chin dan V. Lloyd, “Predicting climate change using an autoregressive long short-term memory model,” *Front Environ Sci*, vol. 12, 2024, doi: 10.3389/fenvs.2024.1301343.
- [6] X. Sun *dkk.*, “A data-to-forecast machine learning system for global weather,” *Nature Communications* , vol. 16, no. 1, Des 2025, doi: 10.1038/s41467-025-62024-1.
- [7] F. Sevgin, “Machine Learning-Based Temperature Forecasting for Sustainable Climate Change Adaptation and Mitigation,” *Sustainability (Switzerland)*, vol. 17, no. 5, Mar 2025, doi: 10.3390/su17051812.
- [8] G. Camps-Valls *dkk.*, “Artificial intelligence for modeling and understanding extreme weather and climate events,” 1 Desember 2025, *Nature Research*. doi: 10.1038/s41467-025-56573-8.
- [9] A. Palacios Gutiérrez, J. L. Valencia Delfa, dan M. Villeta López, “Time series clustering using trend, seasonal and autoregressive components to identify maximum temperature patterns in the Iberian

- Peninsula,” *Environ Ecol Stat*, vol. 30, no. 3, hlm. 421–442, Sep 2023, doi: 10.1007/s10651-023-00572-9.
- [10] S. Bosson-Amedenu, E. M. Baah, F. Ayiah-Mensah, dan J. A. Addor, “Advanced time series modelling to address seasonal variability and extreme rainfall in Ghana,” *BMC Environmental Science*, vol. 2, no. 1, Jun 2025, doi: 10.1186/s44329-025-00024-8.
- [11] Y. Wang, X. Wang, X. Li, W. Liu, dan Y. Yang, “Future Climate Prediction Based on Support Vector Machine Optimization in Tianjin, China,” *Atmosphere (Basel)*, vol. 14, no. 8, Agu 2023, doi: 10.3390/atmos14081235.
- [12] J. T. Hancock dan T. M. Khoshgoftaar, “CatBoost for big data: an interdisciplinary review,” *J Big Data*, vol. 7, no. 1, Des 2020, doi: 10.1186/s40537-020-00369-8.
- [13] G. Ke dkk., “LightGBM: A Highly Efficient Gradient Boosting Decision Tree.” [Daring]. Tersedia pada: <https://github.com/Microsoft/LightGBM>.
- [14] S. Hochreiter dan J. ” Urgen Schmidhuber, “Long Short-Term Memory.”
- [15] J. Hou, Y. Wang, J. Zhou, dan Q. Tian, “Prediction of hourly air temperature based on CNN–LSTM,” *Geomatics, Natural Hazards and Risk*, vol. 13, no. 1, hlm. 1962–1986, 2022, doi: 10.1080/19475705.2022.2102942.
- [16] Q. Cao, Y. Wu, J. Yang, dan J. Yin, “Greenhouse Temperature Prediction Based on Time-Series Features and LightGBM,” *Applied Sciences (Switzerland)*, vol. 13, no. 3, Feb 2023, doi: 10.3390/app13031610.
- [17] F. Z. Che Rose, N. A. K. Rosili, dan M. F. Marsani, “Comparison of machine learning model performance for predicting the climate variables in Johor Bahru, Malaysia,” *Sci Rep*, vol. 15, no. 1, Des 2025, doi: 10.1038/s41598-025-08033-y.
- [18] X. Mao dkk., “A variable weight combination prediction model for climate in a greenhouse based on BiGRU-Attention and LightGBM,”

- Comput Electron Agric*, vol. 219, Apr 2024, doi: 10.1016/j.compag.2024.108818.
- [19] Y. Yang, S.-H. Lee, Y.-S. Choi, dan K.-M. Lee, “LightGBM Medium-Term Photovoltaic Power Prediction Integrating Meteorological Features and Historical Data,” *Energies (Basel)*, vol. 18, no. 20, hlm. 5526, Okt 2025, doi: 10.3390/en18205526.
- [20] H. R. Zhuang, F. Lehner, dan A. T. Degaetano, “Improved Diagnosis of Precipitation Type with LightGBM Machine Learning,” *J Appl Meteorol Climatol*, vol. 63, no. 3, hlm. 437–453, 2024, doi: 10.1175/JAMC-D-23-0117.1.

LAMPIRAN

Repositori Proyek Penelitian

Seluruh kode, model, dan dokumentasi pendukung dari penelitian ini tersedia secara terbuka melalui repositori GitHub berikut:

Tautan repositori:

<https://github.com/Cognivio/Intelecta-Cup-Data-Mining-2025>

Repositori ini mencakup:

1. Folder **/notebooks** – berisi Jupyter Notebook untuk preprocessing, pelatihan model, dan evaluasi.
2. Folder **/data** – berisi contoh subset dataset (data suhu tahunan 1990–2024).
3. Folder **/output** – menyimpan output berupa hasil beberapa preprocessing dan final submission
4. File **README.md** – menjelaskan struktur proyek, pustaka yang digunakan, dan cara menjalankan eksperimen.